MLOPS II · TP FINAL · CEIA-FIUBA

Pronóstico de demanda de Gout en producción

Airflow · MLflow · MinIO · REST · GraphQL · gRPC · Kafka · monitoreo de drift

Andrea Ferenaz · Octubre 2026

EL CASO

Cada día, 9 sucursales le piden a la planta cuánto producir de cada producto

9
sucursales, anonimizadas como S01–S09

20
SKUs en una muestra estratificada por volumen, de 101 series

84.420
pedidos diarios 2023–2025: train 2023–24, test 2025

Punto de partida: el XGBoost que ganó en mi memoria de especialización, con feriados y clima como variables externas.

ALCANCE

Capas

Capa	Implementación	Estado
Base · Docker	Airflow, MLflow, PostgreSQL, MinIO y FastAPI en Docker Compose	Incluida
S1 · REST	FastAPI: /predict y /predict/batch	Incluida
S2 · GraphQL	Strawberry: query pronostico	Incluida
S3 · gRPC	Predict, PredictBatch y Reload	Incluida
S4 · Streaming	Kafka: pedidos → alertas de pedido atípico	Incluida
S5 · Data lake	MinIO: datos, artefactos y reportes	Incluida
S7 · Monitoreo	Drift (PSI estacional) y degradación online	Incluida

ARQUITECTURA

Airflow entrena, MLflow publica y el modelo se sirve por cuatro vías

Airflow
etl_gout → train_gout
drift_gout semanal

→

MLflow
registry de modelos
alias prod = champion

→

Capa de serving
gout_common.serving
rezagos + modelo prod

SIRVEN	REST + GraphQL · :8800	gRPC · :50051	Kafka · alertas
DATOS	MinIO · data lake	PostgreSQL · gout_db	APIs: feriados, clima

PIPELINE

Seis tareas llevan los datos crudos al modelo en producción

etl_gout

1 · Extraer
CSV de MinIO, validado

2 · Externas
feriados y clima

3 · Features
13 atributos, split 2025

train_gout

4 · Entrenar
XGBoost a MLflow

5 · Promover
solo si mejora el RMSE

6 · Recargar
avisa a la API

Las features viven en un único módulo que usan el entrenamiento y el serving: 200 filas de 2025 dan exactamente lo mismo por los dos caminos.

CHAMPION / CHALLENGER

Un modelo nuevo solo llega a producción si mejora el RMSE

Modelo en prod, test 2025

2,70 RMSE

1,92 MAE

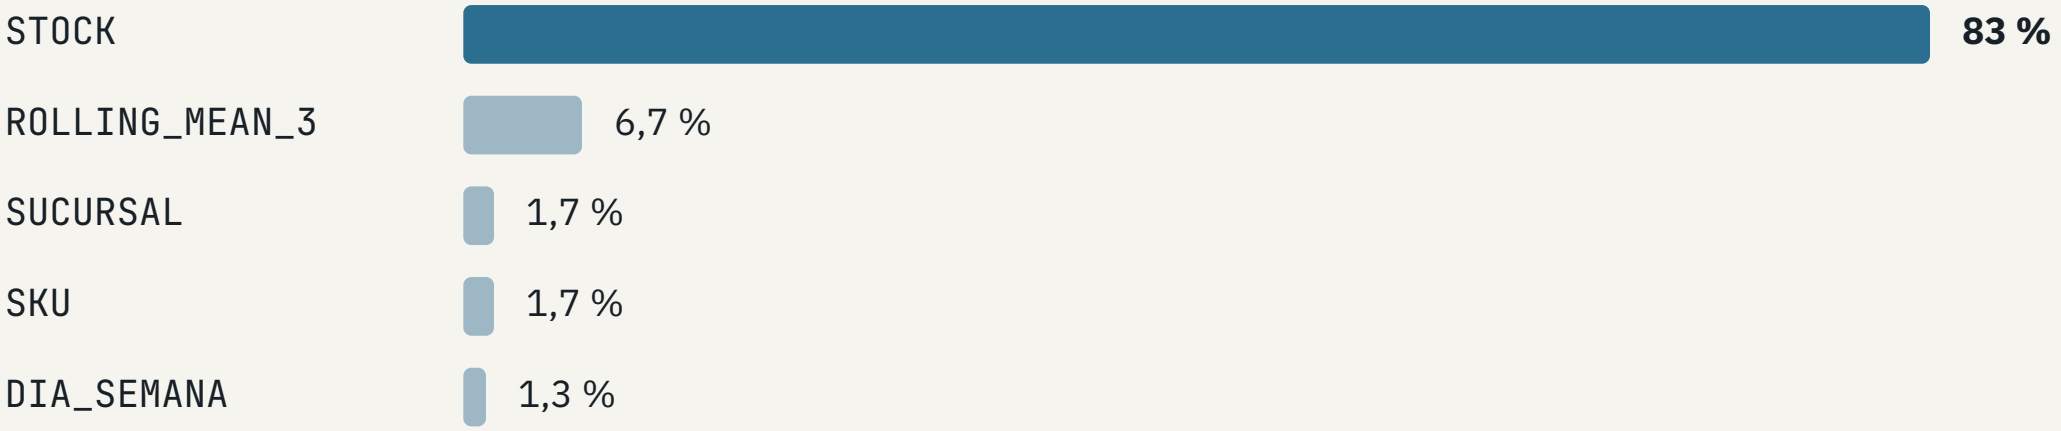
0,77 R^2

Sobre la muestra de 20 SKUs: no comparable con la memoria, que usó las 101 series.

Versión	Estado en MLflow
v1	champion · alias prod
v2	rechazada: empata con v1
v3	rechazada: empata con v1

QUÉ APRENDIÓ EL MODELO

El stock que informa la sucursal explica el 83 % del pronóstico



Implicancia operativa: si la sucursal carga mal su stock al pedir, el pronóstico se degrada. Las 8 variables restantes suman 6 %.

SERVING · S1 S2 S3

Tres protocolos, una sola lógica: misma respuesta, distinta latencia

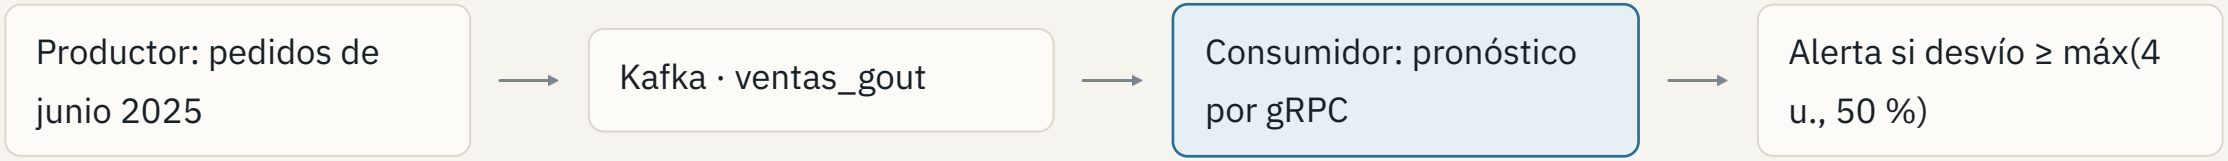
Protocolo	Interfaz	p50 (ms)	p95 (ms)
gRPC	Predict · PredictBatch · Reload	72,9	118,7
REST	POST /predict · /predict/batch	75,3	123,8
GraphQL	query pronostico(sucursal, fecha, items)	79,7	128,6

≈ 65 ms son comunes a los tres
modelo + consulta de la historia en PostgreSQL

El transporte suma 10–20 ms
gRPC el más liviano, GraphQL el más pesado

STREAMING · S4

Kafka marca los pedidos atípicos antes del despacho



2.160
pedidos evaluados

189
alertas (8,8 %)

88 %
son de sobrepedido

1,83
MAE online (test: 1,92)

El sesgo al sobrepedido refleja picos que el modelo no anticipa. S07 concentra 7 de las 10 alertas mayores.

MONITOREO · S7

Un DAG semanal decide si hay que reentrenar

Drift de datos
PSI por atributo contra los mismos meses de train

Degradación
MAE online contra MAE de test, +20 %

Decisión
≥ 30 % con drift o degrada: ETL + entrenamiento

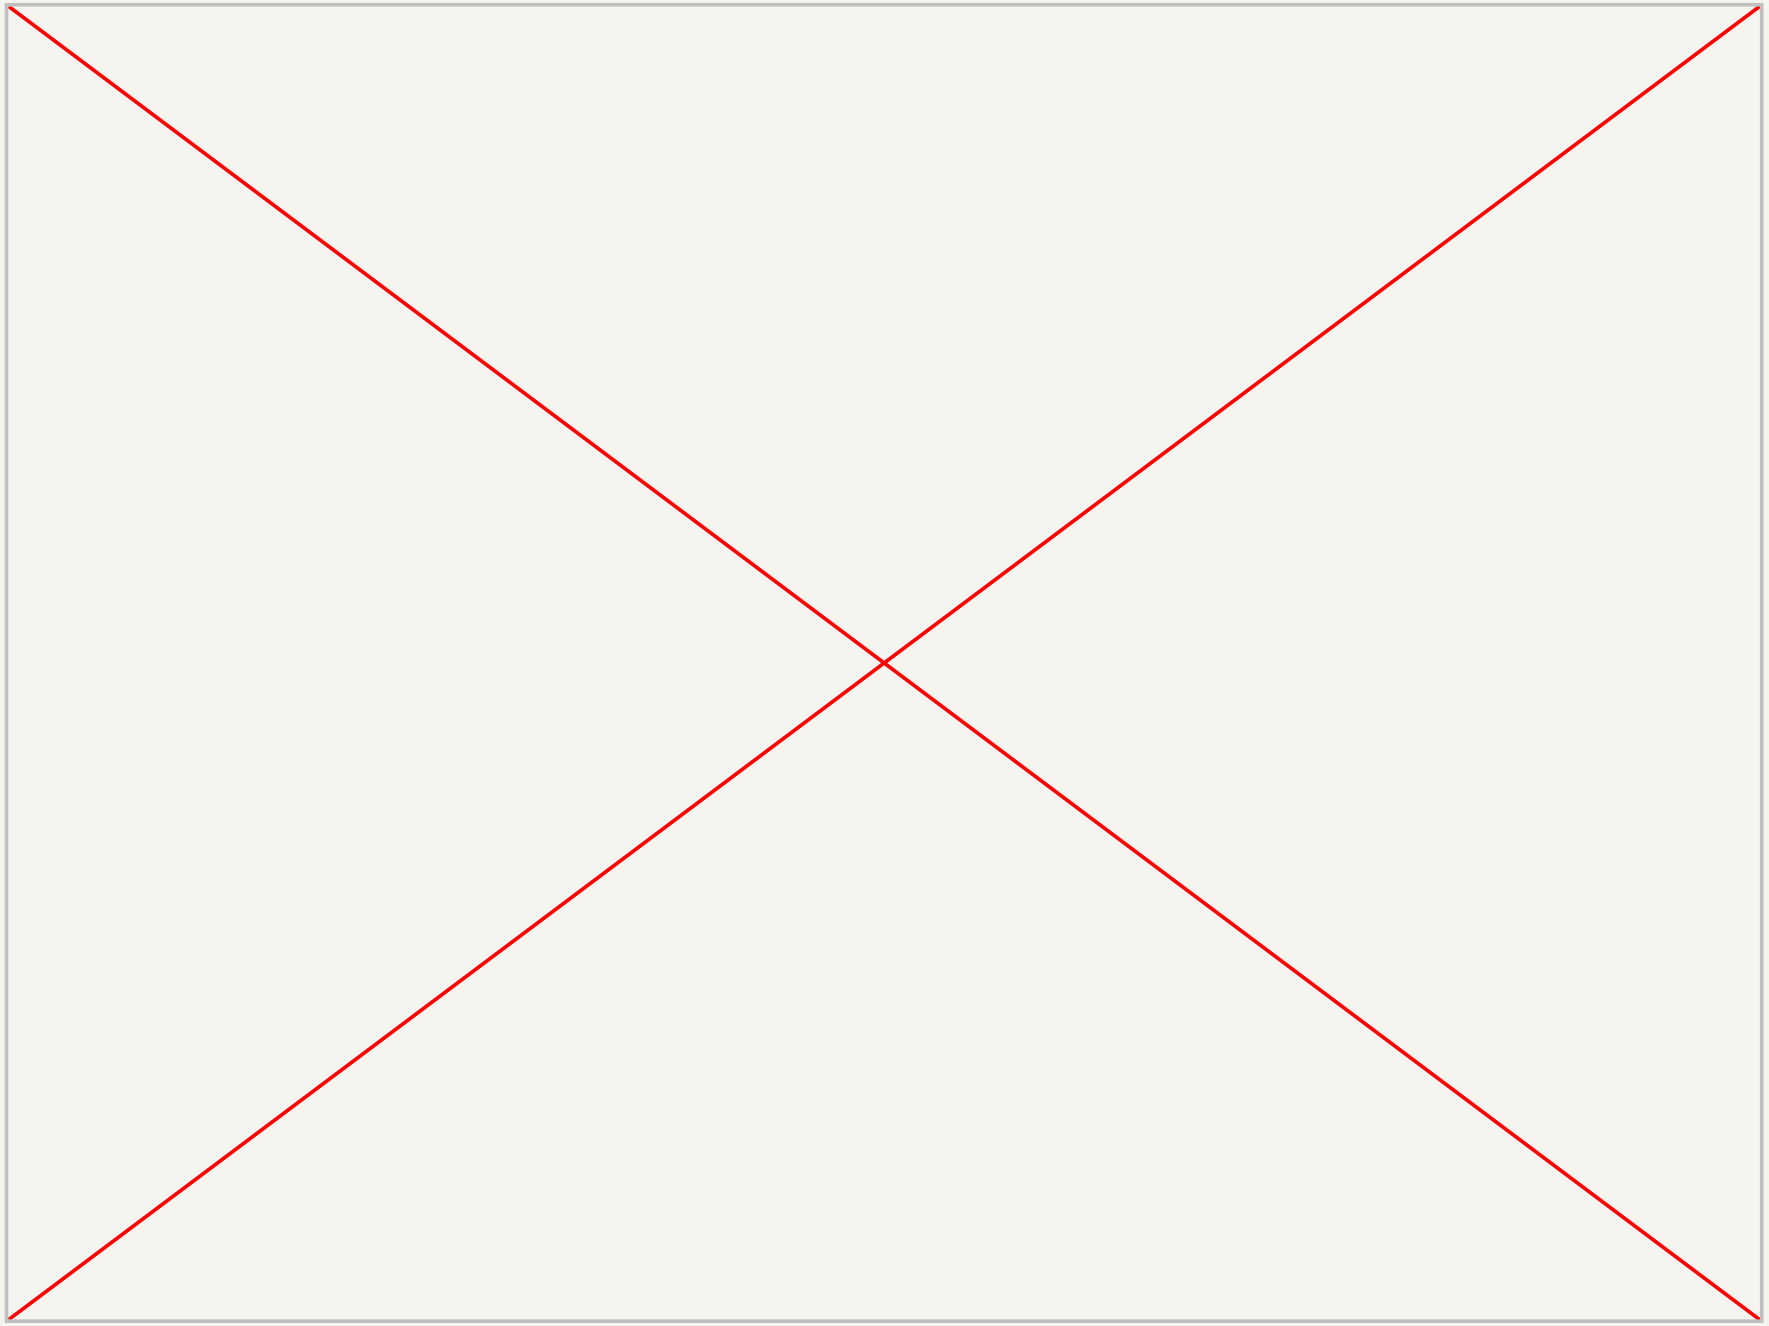
Escenario	Con drift	MAE on / test	Resultado
Real, junio 2025	ninguno	1,91 / 1,92	sin acción
Simulado: stock +80 %, pedidos +40 %	7 de 8	—	reentrena; prod se mantiene

DEMO EN DOCKER

Todo corre con un docker compose up, probado en GitHub Codespaces

Componente	Resultado
Servicios	Postgres, MinIO, MLflow, Airflow, API, gRPC y Kafka healthy
etl_gout	5 tareas OK; encadenó train_gout
train_gout	v1 en prod; v2 y v3 empataron y no se promovieron
REST	POST /predict: HTTP 200, 2 unidades, modelo v1
GraphQL	2 SKUs en una consulta: 10 y 9 unidades
Kafka	alertas de sobrepedido y subpedido en tiempo real
drift_gout	sin drift; reentrenar salteada

DEMO EN VIDEO



LECCIONES

Llevarlo a Docker obligó a resolver cuatro problemas reales

Síntoma	Causa	Solución
pull access denied minio/minio	MinIO retiró sus imágenes de Docker Hub	imagen de Chainguard + script de buckets
MLflow unhealthy	MLflow 2.22 no soporta SQLAlchemy 2.1	fijar sqlalchemy < 2.1
to_sql falla en Airflow	pandas 2.3 con el SQLAlchemy 1.4 de Airflow	fijar pandas 2.1.4
Airflow redirige a localhost	proxy de Codespaces	ENABLE_PROXY_FIX

La lección: en MLOps fijar versiones no es un detalle, es lo que hace reproducible el sistema.

CONCLUSIÓN

El ciclo está cerrado: el monitoreo dispara el reentrenamiento y el champion/challenger protege producción

TRABAJO FUTURO

Federado (S6)
cada sucursal entrena con sus pedidos sin compartirlos

Pérdida cuantílica
corregir el sesgo hacia el sobrepedido

Ventanas móviles
reentrenar incorporando 2025